ANALISIS BIG DATA UNTUK DETEKSI DINI MAHASISWA BERISIKO GAGAL ATAU WITHDRAWAL PADA PEMBELAJARAN DARING: STUDI KASUS *THE OPEN UNIVERSITY*, UNITED KINGDOM

Dosen Pengampu:

Dr. Eng. Agussalim, S.Pd, M.T

Oleh:

Mohammad Bayu Rizki 230820100054

Parallel B

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS ILMU KOMPUTER

UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN" JAWA TIMUR

SURABAYA

2026

BAGIAN A. ANALISIS ORGANISASI

A.1 Profil Organisasi

The Open University adalah universitas di Inggris yang berfokus pada pembelajaran jarak jauh (PJJ) yang berdiri pada tahun 1969 melalui *Royal Charter* dan selama lebih dari 50 tahun dikenal sebagai pelopor *distance learning* selama lebih dari 5 dekade. Misi universitas ini adalah membuka akses pendidikan bagi semua orang melalui pendidikan tinggi yang berkualitas, fleksibel, dan inklusif(The Open University, n.d.). Dalam operasionalnya, *The Open University* menerapkan model *Supported Open Learning*, yaitu pembelajaran jarak jauh yang didukung materi belajar yang lengkap, tutor personal, tutorial kelompok atau *online*, serta forum pembelajaran. Pada studi kasus ini, proses pembelajaran direpresentasikan melalui dataset OULAD yang memuat data anonim mengenai modul, mahasiswa, registrasi, asesmen, dan interaksi mahasiswa dengan *Virtual Learning Environment*. Dengan data tersebut, institusi dapat memantau keterlibatan belajar mahasiswa serta mengembangkan analisis untuk mendeteksi lebih dini mahasiswa yang berisiko gagal atau mengundurkan diri dari modul pembelajaran daring.

A.2 Permasalahan Utama

Permasalahan utama di studi kasus ini adalah kampus belum optimal dalam mendeteksi sejak awal mahasiswa yang berisiko gagal atau *withdrawal* pada pembelajaran daring (Doijode et al., n.d.). Padahal, *The Open University* menjalankan model pembelajaran jarak jauh (PJJ) berbasis teknologi dan memiliki data aktivitas mahasiswa di sistem belajar digital. Data ini bisa dimanfaatkan untuk mengenali penurunan keterlibatan belajar, keterlambatan asesmen, dan tanda-tanda risiko akademik lebih cepat.

A.3 Tujuan Utama Organisasi

Tujuan dari *The Open University* adalah menyediakan pendidikan tinggi yang terbuka, fleksibel, dan berkualitas untuk masyarakat luas. Misinya menekankan keterbukaan terhadap *people, places, methods, and ideas,* serta mendorong kesempatan pendidikan dan keadilan sosial melalui *supported open learning (The Open University, n.d.).*

A.4 Tujuan Strategis

1. Meningkatkan retensi mahasiswa, yaitu menurunkan jumlah mahasiswa yang gagal atau withdrawal.
2. Meningkatkan keberhasilan akademik mahasiswa melalui pemantauan aktivitas belajar dan hasil asesmen.
3. Memperkuat pengambilan keputusan berbasis data agar dosen, tutor, dan tim support dapat memberi intervensi lebih cepat dan tepat.

A.5 Proses Bisnis Utama

1. Pengelolaan pembelajaran modul, yaitu universitas menawarkan modul pada periode tertentu lalu menyediakan materi dan aktivitas belajar secara daring.
2. Pelaksanaan asesmen dan evaluasi hasil belajar, yaitu mahasiswa mengerjakan tugas atau ujian dan hasilnya digunakan untuk menilai performa akademik.
3. Layanan dukungan mahasiswa, yaitu tutor dan tim support memantau perkembangan belajar mahasiswa lalu memberi bantuan saat ada tanda risiko.

BAGIAN B. ANALISIS KEBUTUHAN DATA

B.1 KPI Utama

Tabel 1. KPI sistem deteksi risiko *withdrawal.*

No	KPI	Definisi	Tujuan
1.	*Withdrawal Rate*	Persentase mahasiswa yang keluar dari modul sebelum selesai	Mengetahui tingkat pengunduran diri mahasiswa
2.	*Fail Rate*	Persentase mahasiswa yang tidak lulus modul	Mengukur tingkat kegagalan akademik mahasiswa
3.	*Student Engagement Rate*	Tingkat keterlibatan mahasiswa dalam aktivitas belajar di VLE	Menilai keaktifan mahasiswa selama pembelajaran
4.	*Assessment Completion Rate*	Persentase asesmen yang dikerjakan atau dikumpulkan mahasiswa	Mengukur kepatuhan mahasiswa dalam mengikuti evaluasi belajar
5.	*Early Risk Detection Rate*	Persentase mahasiswa berisiko yang berhasil teridentifikasi lebih awal	Mengukur efektivitas sistem deteksi dini

Lima KPI utama pada studi kasus ini adalah *Withdrawal Rate, Pass Rate, Student Engagement Rate, Assessment Completion Rate,* dan *Early Risk Detection Rate*. KPI tersebut dipilih karena paling sesuai untuk mengukur keberhasilan pembelajaran daring, tingkat keterlibatan mahasiswa, serta efektivitas sistem deteksi dini mahasiswa berisiko gagal atau *withdrawal(Doijode et al., n.d.)*.

B.2 Data yang dibutuhkan

Tabel 2. Kebutuhan data untuk sistem.

No	Kebutuhan Data	Fungsinya

1.	Data identitas akademik mahasiswa.	Mengidentifikasi mahasiswa yang dianalisis.
2.	Data modul dan periode pembelajaran.	Menentukan konteks modul yang sedang diambil.
3.	Data registrasi mahasiswa.	Mengetahui kapan mahasiswa mulai ikut dan kapan keluar dari modul.
4.	Data hasil akhir.	Menentukan label target: *pass*, *fail*, *withdrawal.*
5.	Data aktivitas belajar di VLE	Mendeteksi penurunan *engagement*.
6.	Data materi pembelajaran.	Mengetahui jenis resource yang diakses.
7.	Data asesmen.	Mengukur progres dan performa akademik.
8.	Data profil dasar mahasiswa.	Membantu segmentasi risiko.

Untuk membangun sistem deteksi dini mahasiswa berisiko gagal atau *withdrawal*, dibutuhkan data yang dapat menunjukkan siapa mahasiswanya, modul apa yang diambil, bagaimana aktivitas belajarnya, bagaimana hasil asesmennya, dan bagaimana hasil akhirnya. Oleh karena itu, data yang dibutuhkan meliputi data identitas mahasiswa, data modul dan periode pembelajaran, data registrasi, data aktivitas pada *Virtual Learning Environment* (VLE), data asesmen, data hasil akhir, serta data profil dasar mahasiswa. Data tersebut penting karena dapat digunakan untuk mengenali tanda awal risiko, seperti rendahnya interaksi belajar, keterlambatan pengumpulan tugas, nilai asesmen yang rendah, atau pengunduran diri dari modul. Kombinasi data ini menjadi dasar bagi organisasi untuk membangun sistem *early warning* yang mampu mendeteksi mahasiswa berisiko secara lebih cepat dan tepat.

B.3 Data Tersedia dan Data tidak Tersedia (Gap)

Tabel 3. Data yang tersedia.

No	Data yang tersedia	Tabel dataset
1.	Identitas Mahasiswa	*studentInfo.csv, studentRegistration.csv, studentAssessment.csv, studentVle.csv*
2.	Data modul dan periode	*courses.csv*
3.	Data registrasi	*studentRegistration.csv*
4.	Data hasil akhir	*studentInfo.csv*
5.	Data aktivitas belajar di VLE	*studentVle.csv*
6.	Data materi pembelajaran	*vle.csv*
7.	Data asesmen modul	*assessments.csv*
8.	Data hasil asesmen mahasiswa	*studentAssessment.csv*
9.	Data profil dasar mahasiswa	*studentInfo.csv*

Tabel 4. Data yang tidak tersedia (Gap).

No	Data yang tersedia
1.	Alasan mahasiswa *withdrawal*
2.	Data komunikasi dengan tutor
3.	Data kondisi ekonomi mahasiswa
4.	Data motivasi dan kondisi psikologis
5.	Data kehadiran kelas sinkron
6.	Data intervensi kampus

Berdasarkan analisis kebutuhan data, dapat disimpulkan bahwa dataset OULAD sudah menyediakan data inti yang cukup untuk membangun sistem deteksi dini mahasiswa berisiko gagal atau withdrawal, seperti data registrasi, aktivitas mahasiswa pada VLE, hasil asesmen, hasil akhir, serta profil dasar mahasiswa. Data-data tersebut sudah memadai untuk mengidentifikasi pola risiko akademik sejak awal pembelajaran. Namun, masih terdapat beberapa gap data, seperti alasan *withdrawal*, komunikasi dengan tutor, kehadiran kelas sinkron, dan data intervensi kampus. Ketiadaan data tersebut tidak menghalangi pembangunan sistem deteksi dini, tetapi membuat analisis menjadi kurang lengkap dalam menjelaskan penyebab risiko dan menentukan tindak lanjut yang paling tepat. Dengan demikian, data yang tersedia sudah cukup untuk analisis awal dan pengembangan *early warning system*, sedangkan data yang belum tersedia dapat dipertimbangkan sebagai pengembangan lanjutan agar sistem menjadi lebih akurat.

BAGIAN C. DESAIN DATA LIFECYCLE

C.1 Data Acquisition

	Dataset	Kolom	Jumlah Missing Values
0	assessments	date	11
1	studentAssessment	score	173
2	studentInfo	imd_band	1111
3	studentRegistration	date_unregistration	22521
4	studentRegistration	date_registration	45
5	vle	week_from	5243
6	vle	week_to	5243

Berdasarkan tahap *data acquisition*, seluruh file utama pada dataset OULAD berhasil dikumpulkan dan dibaca ke dalam Google Colab tanpa kendala. Hasil pengecekan awal menunjukkan bahwa sebagian besar atribut sudah terisi dengan baik, namun masih terdapat beberapa *missing values* pada beberapa tabel, seperti *date* pada

assessments, score pada *studentAssessment, imd_band* pada *studentInfo, date_unregistration* pada *studentRegistration, date_registration* pada *studentRegistration, week_from* pada *vle,* dan *week_to* pada *vle*. Sementara itu, tabel *studentVle* dan *course* tidak memiliki *missing values* sehingga dapat dianggap paling lengkap pada tahap akuisisi. Temuan ini menunjukkan bahwa proses pengambilan data telah berhasil, tetapi data yang diperoleh belum sepenuhnya siap untuk langsung dianalisis. Oleh karena itu, tahap berikutnya perlu dilakukan data cleaning dan penanganan *missing values* agar kualitas data menjadi lebih baik sebelum masuk ke proses integrasi dan analisis.

C.2 Data Storage

```
... /
    data/
        raw/
            studentAssessment.csv
            studentVle.csv
            assessments.csv
            vle.csv
            studentInfo.csv
            courses.csv
            studentRegistration.csv
        processed/
            merged_processed_oulad.csv
        output/
    notebooks/
        Data Acquisition.ipynb
        Data Processing.ipynb
    reports/
        figure/
```

Pada tahap *data storage*, seluruh data OULAD disimpan di Google Drive sebagai penyimpanan cloud sederhana. Data mentah ditempatkan pada folder *raw*, data hasil pembersihan dan integrasi pada folder *processed*, sedangkan hasil analisis dan prediksi disimpan pada folder *output*. Penyimpanan ini memudahkan pengelolaan data dan akses dari Google Colab untuk proses berikutnya.

C.3 Data Processing

a. Data Cleaning

Tabel 5. Hasil Data Cleaning.

Tabel	Kolom yang *missing value*	Jumlah *missing*	Hasil *cleaning*	Alasan
assessment	*date*	11	Diisi Median	Karena kolom numerik dan jumlah *missing* kecil, median aman dipakai agar distribusi data tidak terlalu berubah.
vle	*week_from*	5243	Diisi dengan 0	Karena kolom numerik dan nilai kosong diperlakukan sebagai tidak ada rentang minggu yang jelas.
vle	*week_to*	5243	Diisi dengan 0	Sama seperti *week_from*, untuk menjaga data tetap bisa diproses

studentInfo	*imd_band*	1111	Diisi "*Unknown*"	Karena kolom kategorikal, sehingga lebih tepat diberi label khusus daripada angka.
student Registration	*date Registration*	45	Diisi median	Karena kolom numerik dan missing sedikit, sehingga median cukup aman
student Registration	*date Unregistration*	22521	Tidak diisi tetap kosong	Karena *missing* pada kolom ini memiliki arti, yaitu mahasiswa tidak *withdrawal* dari modul
Student Assessment	*score*	173	Diisi dengan 0	Untuk menandai tidak ada skor / nilai belum tercatat, dan agar data tetap bisa dipakai dalam analisis

Pada tahap *cleaning data*, data dibersihkan dengan cara meninjau *missing values* pada setiap tabel yang sesuai. Berdasarkan hasil pengecekan, ditemukan beberapa kolom yang memiliki nilai kosong seperti pada tabel 5. Dari hasil ini dapat disimpulkan bahwa tidak semua *missing value* diperlakukan sama. Terutama *date_unregistration* tidak langsung dihapus atau diisi sembarang karena nilai kosong pada kolom ini masih memiliki arti, yaitu mahasiswa tidak melakukan *withdrawal*.

b. Data Tranformasi

```python
# Buat flag withdrawal
studentRegistration_clean["is_withdrawn"] = studentRegistration_clean["date_unregistration"].notna().astype(int)

# Buat flag submit assessment
studentAssessment_clean["submitted"] = (studentAssessment_clean["date_submitted"] >= 0).astype(int)

# Total klik per mahasiswa per modul
studentVle_agg = (
    studentVle_clean
    .groupby(["id_student", "code_module", "code_presentation"], as_index=False)
    .agg(
        total_clicks=("sum_click", "sum"),
        avg_clicks=("sum_click", "mean"),
        last_interaction_day=("date", "max"),
        active_days=("date", "nunique")
    )
)
```

Setelah data dibersihkan, tahap berikutnya adalah transformasi, yaitu mengubah data mentah menjadi fitur yang lebih sesuai untuk mendeteksi risiko. Transformasi pertama berhasil membentuk tabel *studentVle_agg* dengan kolom: *id_student, code_module, code_presentation, total_clicks, avg_clicks, last_interaction_day,* dan *active_days*. Transformasi kedua menghasilkan tabel *studentAssessment_agg* dengan kolom: *id_student, code_module, code_presentation, avg_score, max_score, total_assessments, total_submitted,* dan *assessment_completion_rate*. Secara praktis, dua hasil transformasi ini sangat penting karena sistem tidak lagi membaca jutaan interaksi harian dan banyak baris asesmen mentah, tetapi langsung menggunakan fitur yang lebih padat dan bermakna, seperti total klik, hari aktif, rata-rata nilai, dan tingkat penyelesaian asesmen.

c. Data Integrasi

```
Data processing selesai.
Ukuran final data: (32593, 28)
```

	code_module	code_presentation	id_student	gender	region	highest_education	imd_band	age_band	num_of_prev_attempts	studied_credits	...	active_d
0	AAA	2013J	11391	M	East Anglian Region	HE Qualification	90-100%	55<=	0	240	...	4
1	AAA	2013J	28400	F	Scotland	HE Qualification	20-30%	35-55	0	60	...	8
2	AAA	2013J	30268	F	North Western Region	A Level or Equivalent	30-40%	35-55	0	60	...	1
3	AAA	2013J	31604	F	South East Region	A Level or Equivalent	50-60%	35-55	0	60	...	12
4	AAA	2013J	32885	F	West Midlands Region	Lower Than A Level	50-60%	0-35	0	60	...	7

5 rows × 28 columns

Tahap terakhir adalah integrasi, yaitu menggabungkan *studentInfo_clean, studentRegistration_clean, studentVle_agg, studentAssessment_agg,* dan *courses_clean* berdasarkan *id_student, code_module,* dan *code_presentation*. Tujuannya agar setiap baris data mewakili satu mahasiswa pada satu modul dan satu periode pembelajaran, lengkap dengan profil mahasiswa, status registrasi, aktivitas belajar, performa asesmen, dan informasi modul. Hasil integrasi ini adalah *merged_data*, yaitu dataset utama yang digunakan untuk analisis deskriptif, prediktif, dan visualisasi pada early warning system. Pada tahap ini juga ditambahkan fitur langsung ke merged_data, yaitu *risk_label, low_engagement, low_score,* dan *is_withdrawn*. *risk_label* digunakan untuk membedakan mahasiswa berisiko dan tidak berisiko berdasarkan *final_result*, *low_engagement* untuk menandai aktivitas VLE yang rendah, *low_score* untuk menandai performa nilai yang rendah, dan *is_withdrawn* untuk menunjukkan status *withdrawal*. Dengan demikian, *merged_data* menjadi dataset final yang memuat indikator utama risiko akademik.

C.4 Data Analysis

Pada tahap *data analysis*, metode yang digunakan adalah analisis deskriptif dan analisis prediktif. Analisis deskriptif digunakan untuk memahami pola hasil akhir mahasiswa, tingkat aktivitas pada VLE, performa asesmen, dan distribusi withdrawal pada setiap modul. Setelah pola awal dipahami, analisis dilanjutkan dengan metode prediktif untuk membangun sistem early warning mahasiswa berisiko gagal atau withdrawal. Model yang paling cocok digunakan adalah Decision Tree karena mampu mengklasifikasikan mahasiswa berisiko secara jelas, mudah diinterpretasikan, dan dapat menunjukkan variabel yang paling berpengaruh. Selain itu, Logistic Regression dapat digunakan sebagai model pembanding untuk menghitung probabilitas risiko mahasiswa. Pemilihan metode ini sesuai dengan kebutuhan sistem deteksi dini dan juga sejalan dengan referensi studi yang menggunakan pendekatan klasifikasi pada dataset OULA untuk memprediksi keberhasilan mahasiswa.

a. *Analysis Descriptive*

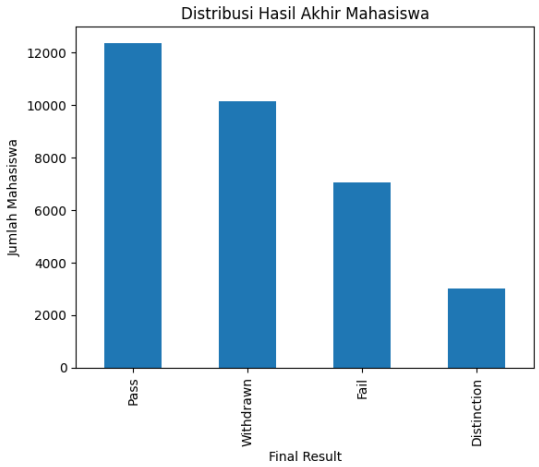

1. **Distribusi hasil akhir mahasiswa**

   Hasil menunjukkan bahwa kategori *Pass* adalah yang paling banyak, disusul *Withdrawn*, lalu *Fail*, dan yang paling sedikit *Distinction*. Ini berarti secara umum cukup banyak mahasiswa yang berhasil lulus, tetapi jumlah mahasiswa yang *withdrawal* juga masih tinggi, sehingga masalah early warning memang relevan. Fokus sistem nanti bukan hanya mencegah fail, tetapi juga menekan *withdrawal*.

2. **Persentase *final result* per modul**

   Hasil Interpretasi, risiko akademik tidak merata antar modul. Jadi nanti sistem *early warning* sebaiknya juga memperhatikan faktor modul, bukan hanya perilaku mahasiswa secara umum.

3. **Rata-rata total clicks berdasarkan final result**

   Hasil Interpretasi, semakin tinggi keterlibatan mahasiswa di VLE, semakin baik hasil akhirnya. Mahasiswa yang jarang berinteraksi dengan materi cenderung lebih berisiko gagal atau *withdrawal*. Ini mendukung bahwa aktivitas VLE sangat layak dijadikan indikator *early warning*.

4. **Rata-rata *avg score* berdasarkan *final result***

   Hasil Interpretasi, nilai asesmen sangat berkaitan dengan hasil akhir. Mahasiswa yang skornya rendah cenderung lebih dekat ke kategori *fail* atau *withdrawn*. Jadi *avg_score* sangat cocok dipakai sebagai sinyal risiko akademik.

5. **Rata-rata *assessment completion rate* berdasarkan final result**

   Hasil Interpretasi, mahasiswa yang menyelesaikan asesmen lebih lengkap cenderung lulus, sedangkan mahasiswa yang banyak tidak menyelesaikan tugas sangat rentan withdrawal. Jadi *assessment_completion_rate* adalah indikator *early warning* yang sangat kuat.

6. **Tabel low_engagement vs final_result**

   Hasil Interpretasi, mahasiswa dengan engagement rendah jauh lebih banyak masuk kategori *Fail* dan terutama *Withdrawn*. Ini berarti fitur *low_engagement* berhasil menangkap gejala awal risiko.

7. **Tabel low_score vs final_result**

Hasil Interpretasi, mahasiswa dengan skor rendah sangat rentan gagal atau *withdrawal*. Jadi *low_score* juga berhasil menjadi indikator risiko yang kuat.

8. **Distribusi risk label**

   Hasil Interpretasi, jumlah mahasiswa yang dikategorikan berisiko sedikit lebih besar daripada yang tidak berisiko. Ini menunjukkan bahwa data Anda memang cukup kaya untuk kasus *early warning*, karena kelompok risiko tidak terlalu kecil.

Hasil analisis deskriptif menunjukkan bahwa mahasiswa dengan tingkat keterlibatan VLE yang rendah, nilai asesmen yang rendah, dan tingkat penyelesaian asesmen yang rendah cenderung memiliki risiko lebih tinggi untuk gagal atau *withdrawal*, sementara pola hasil akhir juga berbeda antar modul sehingga faktor modul perlu diperhatikan dalam sistem *early warning*.

b. *Analysis Predictive*

Analisis prediktif untuk membangun sistem *early warning* mahasiswa berisiko gagal atau *withdrawal*. Pada tahap ini, Decision Tree digunakan sebagai model utama karena mampu membagi data ke dalam cabang keputusan yang mudah dipahami, sedangkan *Logistic Regression* digunakan sebagai model pembanding untuk melihat performa prediksi berbasis probabilitas.

1. ***Decision Tree* sebagai model utama**

```
•••  Accuracy Decision Tree: 0.930357416781715

     Confusion Matrix:
     [[2975  102]
      [ 352 3090]]

     Classification Report:
                   precision    recall  f1-score   support

                0       0.89      0.97      0.93      3077
                1       0.97      0.90      0.93      3442

         accuracy                           0.93      6519
        macro avg       0.93      0.93      0.93      6519
     weighted avg       0.93      0.93      0.93      6519
```

   Decision Tree mampu mengklasifikasikan mahasiswa berisiko dan tidak berisiko dengan sangat baik. Nilai *accuracy* 93.04% menunjukkan bahwa mayoritas prediksi model benar. Untuk kelas mahasiswa berisiko, nilai *precision* 0.97 berarti ketika model menyatakan seorang mahasiswa berisiko, prediksi itu benar dalam sekitar 97% kasus. Nilai *recall* 0.90 menunjukkan bahwa sekitar 90% mahasiswa yang memang berisiko berhasil terdeteksi oleh model.

2. ***Logistic Regression* sebagai model pembanding**

```
Accuracy Logistic Regression: 0.9271360638134684

Confusion Matrix:
[[2969  108]
 [ 367 3075]]

Classification Report:
              precision    recall  f1-score   support

           0       0.89      0.96      0.93      3077
           1       0.97      0.89      0.93      3442

    accuracy                           0.93      6519
   macro avg       0.93      0.93      0.93      6519
weighted avg       0.93      0.93      0.93      6519
```

Hasil pengujian model *Logistic Regression* menunjukkan performa yang baik dengan *accuracy* sebesar 92.71%. Pada kelas mahasiswa berisiko (1), model menghasilkan *precision* sebesar 0.97, *recall* sebesar 0.89, dan *F1-score* sebesar 0.93. Hasil ini menunjukkan bahwa model sangat baik dalam memprediksi mahasiswa yang benar-benar berisiko, serta cukup mampu menangkap sebagian besar mahasiswa berisiko dalam data uji. Dalam konteks *early warning system*, nilai *recall* pada kelas berisiko menjadi indikator penting karena menunjukkan kemampuan sistem dalam mendeteksi mahasiswa yang membutuhkan perhatian lebih awal. Dengan demikian, *Logistic Regression* dapat dianggap sebagai model yang cukup kuat untuk mendukung deteksi dini mahasiswa berisiko gagal atau *withdrawal*.

3. **Perbandingan kedua model**

	Model	Accuracy	Precision	Recall	F1-Score
0	Decision Tree	0.930357	0.968045	0.897734	0.931565
1	Logistic Regression	0.927136	0.966070	0.893376	0.928302

Hasil analisis prediktif menunjukkan bahwa kedua model, yaitu *Decision Tree* dan *Logistic Regression*, memiliki performa yang sangat baik dalam mendeteksi mahasiswa berisiko. Namun, *Decision Tree* memberikan hasil yang sedikit lebih unggul dengan *accuracy* 93.04%, *precision* 96.80%, *recall* 89.77%, dan *F1-score* 93.16%, dibandingkan *Logistic Regression* yang memperoleh *accuracy* 92.71%, *precision* 96.61%, *recall* 89.34%, dan *F1-score* 92.83%. Karena memiliki nilai *recall* dan *F1-score* yang lebih tinggi, *Decision Tree* dipilih sebagai model utama dalam sistem *early warning*, sedangkan *Logistic Regression* digunakan sebagai model pembanding.

C.5 Data Visualization

Pada tahap *data visualization*, hasil analisis ditampilkan dalam bentuk dashboard sederhana berbasis Google Colab. Visualisasi mencakup ringkasan KPI utama, distribusi hasil akhir mahasiswa, persentase hasil akhir per modul, hubungan aktivitas VLE dan performa asesmen dengan final result, perbandingan performa model prediktif, *feature importance Decision Tree*, serta daftar mahasiswa berisiko. Dengan visualisasi ini, pihak

organisasi dapat lebih mudah memahami pola risiko akademik mahasiswa dan menggunakan hasil model sebagai dasar intervensi dalam sistem *early warning*.

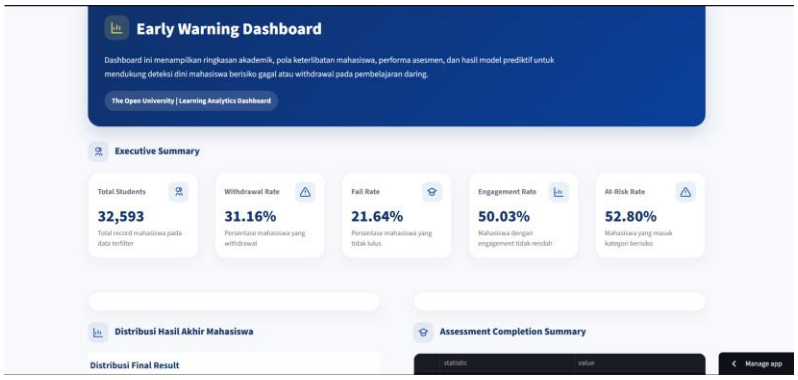

Arsitektur sistem dimulai dari sumber data berupa dataset OULAD dalam format CSV. Data kemudian disimpan pada Google Drive dengan struktur folder *raw*, *processed*, dan *output*. Selanjutnya data diproses di Google Colab melalui tahap *cleaning*, transformasi, dan integrasi hingga menghasilkan dataset utama *merged_processed_oulad*. Dataset ini dianalisis menggunakan metode deskriptif dan prediktif, dengan *Decision Tree* sebagai model utama dan *Logistic Regression* sebagai model pembanding. Hasil analisis kemudian ditampilkan pada dashboard Streamlit dalam bentuk KPI, grafik, perbandingan model, dan daftar mahasiswa berisiko, sehingga dapat digunakan oleh tutor atau pihak kampus untuk melakukan intervensi dini.

BAGIAN D. DATA GOVERNANCE DAN QUALITY

D.1 Data Ownership

Data ownership pada studi kasus ini berada pada *The Open University* sebagai institusi yang mengumpulkan dan mengelola data mahasiswa. Universitas bertindak sebagai pengendali data (*data controller*) atas data pribadi yang digunakan untuk mendukung layanan pendidikan, operasional institusi, dan analitik pembelajaran. Dalam rancangan *early warning system*, pengelolaan data secara operasional dapat berada pada unit akademik atau unit *learning analytics* yang bertanggung jawab terhadap monitoring mahasiswa berisiko.

D.2 Kebijakan Akses Data

Kebijakan akses data pada *early warning system* sebaiknya menggunakan prinsip *role-based access control*, sehingga setiap pengguna hanya dapat mengakses data sesuai tanggung jawabnya. Administrator dan data analyst dapat mengakses data terintegrasi dan hasil model, tutor hanya dapat melihat mahasiswa berisiko pada modul yang relevan,

sedangkan manajemen akademik lebih difokuskan pada akses dashboard dan laporan agregat. Kebijakan ini penting untuk menjaga kerahasiaan data mahasiswa dan konsisten dengan prinsip perlindungan data serta keamanan informasi yang diterapkan oleh *The Open University*.

D.3 Evaluasi Kualitas Data

1. Completeness

index	kolom	jumlah_missing	persentase_missing	completeness_score
13	date_unregistration	22521	69.1	30.9
0	code_module	0	0.0	100.0
2	id_student	0	0.0	100.0
1	code_presentation	0	0.0	100.0
4	region	0	0.0	100.0
5	highest_education	0	0.0	100.0
6	imd_band	0	0.0	100.0
7	age_band	0	0.0	100.0

Completeness dataset tergolong baik karena hampir seluruh kolom utama memiliki missing value 0%. Namun, kolom *date_unregistration* memiliki *missing value* tinggi sebesar 69.1%. Nilai kosong ini tidak selalu menunjukkan kesalahan data, karena pada konteks akademik hal tersebut dapat berarti mahasiswa tidak melakukan *withdrawal*. Dengan demikian, *completeness* data secara umum baik, tetapi ada satu atribut yang perlu ditafsirkan sesuai konteks bisnis.

2. *Accuracy*

index	rule_check	jumlah_pelanggaran
0	assessment_completion_rate_out_of_range	0
1	avg_score_out_of_range	0
2	max_score_out_of_range	0
3	total_clicks_negative	0
4	active_days_negative	0
5	num_of_prev_attempts_negative	0

Show 25 per page

Hasil dari gambar diatas menunjukkan bahwa tidak ada nilai yang dilanggar, skor masih dalam rentang wajar, dan kategori hasil akhir valid semua. Maka kesimpulannya, *Accuracy* data tergolong sangat baik karena tidak ditemukan nilai yang melanggar aturan logis maupun kategori yang tidak valid. Hal ini menunjukkan bahwa data hasil integrasi cukup akurat untuk digunakan dalam analisis *early warning*.

3. *Consistency*

	check	jumlah_duplikat
0	duplicate_key_record	0

```
# Konsistensi label risk dengan final_result
def expected_risk(x):
    return 1 if x in ["Fail", "Withdrawn", "Withdrawal"] else 0

merged_data["expected_risk_label"] = merged_data["final_result"].apply(expected_risk)
inconsistent_risk = (merged_data["risk_label"] != merged_data["expected_risk_label"]).sum()

consistency_label = pd.DataFrame({
    "check": ["risk_label_consistency"],
    "jumlah_tidak_konsisten": [inconsistent_risk]
})

display(consistency_label)
```

	check	jumlah_tidak_konsisten
0	risk_label_consistency	0

Consistency data tergolong sangat baik karena tidak ditemukan duplikasi pada kunci utama, label risiko konsisten dengan hasil akhir mahasiswa, dan referensi antar tabel juga valid. Hal ini menunjukkan bahwa proses integrasi data berhasil dilakukan secara konsisten.

4. *Timeliness*

	timeliness_check	jumlah_masalah
0	registration_after_unregistration	22
1	last_interaction_negative	728

Timeliness data cukup baik, tetapi belum sepenuhnya sempurna. Terdapat 22 record dengan urutan waktu yang tidak logis antara *registration* dan *unregistration*. Selain itu, terdapat 728 record dengan nilai *last_interaction_day* negatif yang perlu ditafsirkan sesuai konteks representasi waktu pada dataset. Dengan demikian, aspek *timeliness* masih memerlukan perhatian lebih dibanding dimensi kualitas data lainnya.

Hasil evaluasi menunjukkan bahwa kualitas data secara umum sudah baik. *Accuracy* dan *consistency* memiliki hasil sangat baik karena tidak ditemukan nilai tidak valid, duplikasi, maupun ketidaksesuaian antar tabel. *Completeness* juga tinggi pada hampir semua kolom, kecuali *date_unregistration* yang memiliki missing value tinggi namun masih dapat dijelaskan secara konteks bisnis. Sementara itu, timeliness menunjukkan beberapa anomali kecil pada data waktu, sehingga perlu dicatat sebagai keterbatasan, tetapi tidak menghalangi penggunaan data untuk analisis *early warning*.

BAGIAN E. SOLUSI DAN DAMPAK

E.1 Solusi yang Diusulkan

Solusi yang diusulkan adalah pembangunan sistem *early warning* berbasis data untuk mendeteksi dini mahasiswa yang berisiko gagal atau *withdrawal* pada pembelajaran daring. Sistem ini memanfaatkan data OULAD yang meliputi profil mahasiswa, registrasi, aktivitas pada *Virtual Learning Environment* (VLE), hasil asesmen, dan hasil akhir pembelajaran. Data diproses melalui tahapan *cleaning*, transformasi, dan integrasi, kemudian dianalisis secara deskriptif dan prediktif menggunakan *Decision Tree* sebagai model utama dan *Logistic Regression* sebagai model pembanding. Hasilnya divisualisasikan dalam bentuk dashboard agar mudah dipahami oleh tutor dan pihak akademik.

Secara fungsional, sistem ini membantu organisasi untuk:

1. mengidentifikasi mahasiswa berisiko lebih awal,
2. memantau indikator utama seperti engagement, nilai asesmen, dan withdrawal rate,
3. mendukung intervensi akademik yang lebih cepat dan tepat sasaran,
4. menyediakan dasar pengambilan keputusan yang lebih berbasis data.

E.2 Dampak Terhadap Organisasi

1. peningkatan kemampuan monitoring mahasiswa,
2. pengambilan keputusan akademik yang lebih objektif,
3. intervensi yang lebih tepat sasaran,

4. peningkatan efisiensi pengelolaan akademik,
5. potensi penurunan tingkat gagal dan withdrawal.

E.3 Nilai Bisnis / Sosial

Dari sisi nilai bisnis, sistem ini membantu organisasi memanfaatkan data akademik secara lebih strategis. Data yang sebelumnya hanya tersimpan sebagai arsip dapat diubah menjadi informasi yang mendukung keputusan, sehingga pengelolaan akademik menjadi lebih efektif dan efisien. Sistem ini juga berpotensi mengurangi kerugian tidak langsung akibat tingginya angka withdrawal dan kegagalan, seperti menurunnya performa akademik dan meningkatnya beban layanan.

Dari sisi nilai sosial, sistem ini mendukung keberhasilan mahasiswa dengan memberikan peluang intervensi lebih awal. Mahasiswa yang mulai menunjukkan gejala risiko dapat segera dibantu, sehingga peluang mereka untuk bertahan dan menyelesaikan modul menjadi lebih besar. Dengan demikian, sistem ini tidak hanya bermanfaat bagi institusi, tetapi juga bagi mahasiswa sebagai penerima layanan pendidikan.

Hasil Turnitin dan AI Checker
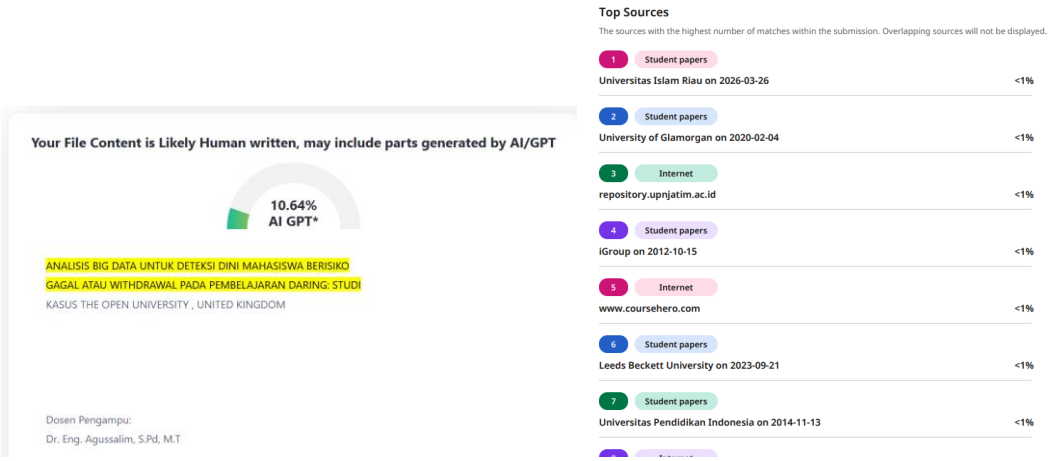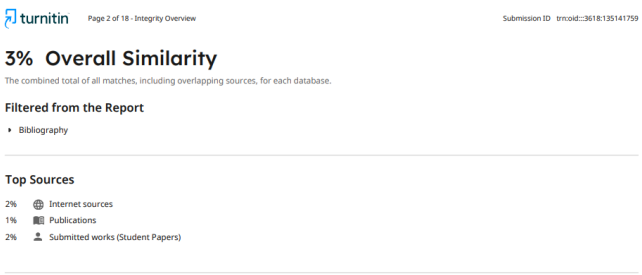
Ai Checker menggunakan zero GPT dan Cek Plagiarisme menggunakan Turnitin